INFORME DE LABORATORIO

Orquestación Automatizada de un Pipeline de Calidad del Aire en India con Apache Airflow

Autor: Santiago Navia Soto

1. Introducción

El monitoreo de la calidad del aire en países de alta densidad poblacional e industrial como India exige integrar información proveniente de distintas fuentes y mantenerla actualizada de forma continua. En este proyecto se implementó un proceso automatizado de extracción, transformación y carga de datos ambientales organizado bajo la arquitectura Medallion (capas Bronze, Silver y Gold) y orquestado cada hora mediante Apache Airflow.

El sistema combina dos insumos complementarios. El primero es un archivo Excel que contiene el inventario físico de estaciones y sensores instalados en territorio indio, detallando su ubicación geográfica, el tipo de contaminante que miden y su historial operativo. El segundo es el servicio web de Open-Meteo (basado en el modelo atmosférico europeo Copernicus CAMS), del cual se obtienen cada hora las concentraciones estimadas de material particulado y gases contaminantes para las coordenadas de dichas estaciones

2. Comparación entre la ejecución por script y la orquestación con Apache Airflow

En una primera versión, todo el flujo de datos dependía de un único programa ejecutado de forma secuencial. Aunque ese enfoque funcionaba para pruebas puntuales, presentaba limitaciones importantes en un escenario real de operación continua. Todas las etapas ocurrían una detrás de otra sin aprovechar que las dos fuentes de origen son independientes entre sí. Además, cualquier inconveniente temporal de conexión a internet interrumpía el proceso completo y obligaba a reiniciarlo manualmente desde cero, sin contar con un panel visual que permitiera auditar en qué punto exacto había ocurrido el fallo ni cuánto tardaba cada fase.

Al migrar el proyecto hacia un flujo de trabajo (DAG) en Apache Airflow, la operación cambió de manera sustancial. En lugar de un bloque rígido, el proceso quedó dividido en cinco etapas claramente delimitadas y supervisadas por un planificador central. Esto permitió consultar el servicio web y leer el catálogo en Excel al mismo tiempo, reduciendo los tiempos de espera. También incorporó tolerancia a fallos por tarea individual: si la consulta externa sufre una caída momentánea de red, Airflow vuelve a intentar únicamente esa extracción sin repetir el trabajo que ya había salido bien. A esto se suma un historial completo de ejecuciones por hora, registros separados para cada etapa y la seguridad de que ninguna transformación avanza si los insumos previos están incompletos.

3. Decisiones de diseño y orquestación del flujo

Organización de etapas y trabajo en paralelo



El flujo automatizado se estructuró en cinco tareas conectadas según su dependencia lógica. Las dos primeras tareas corresponden a la extracción de la API de calidad del aire y a la lectura del archivo Excel hacia la capa Bronze; al no depender una de la otra, se ejecutan en paralelo. La tercera tarea corresponde a la capa Silver y actúa como punto de convergencia: solo se inicia cuando ambas extracciones han finalizado con éxito, encargándose de depurar variables ajenas a la calidad del aire (como temperatura o humedad), corregir unidades, eliminar registros repetidos y cruzar cada estación con su serie horaria. Posteriormente, la cuarta tarea construye la capa Gold calculando los resúmenes diarios, los índices ambientales y actualizando la base de datos analítica en PostgreSQL. Finalmente, una quinta tarea de validación revisa de forma automática que el archivo resultante esté completo y coherente antes de dar por exitosa la corrida. Entre una tarea y otra no se transfieren tablas pesadas en memoria, sino únicamente las rutas de los archivos generados y conteos básicos de control.

- Programación horaria y manejo de zonas horarias



El proceso se configuró para ejecutarse automáticamente cada hora en el minuto cero, desactivando las corridas retroactivas para evitar saturar el servicio público al encender el sistema por primera vez, y permitiendo una sola ejecución activa a la vez para impedir escrituras simultáneas sobre los mismos archivos. En cuanto al manejo del tiempo, se separó la zona horaria operativa de la zona horaria de análisis: el planificador de Airflow trabaja en tiempo universal coordinado (UTC) para mantener un orden cronológico uniforme en el servidor, mientras que los datos ambientales se solicitan en la hora oficial de India (Asia/Kolkata, UTC+5:30), garantizando que los promedios diarios coincidan con el día calendario local de las ciudades evaluadas.

- Manejo de errores, reintentos y validación de calidad

Para asegurar la continuidad del servicio frente a intermitencias externas, se definieron dos niveles de protección. Durante la descarga de datos, el conector reintenta de forma escalonada cuando detecta saturación temporal o fallos del servidor remoto. Si aun así la tarea falla, Apache Airflow aplica una política automática de hasta dos reintentos adicionales espaciados por cinco minutos,

bloqueando mientras tanto las etapas siguientes para no procesar información parcial. Al cierre del flujo, la etapa de validación comprueba que el archivo final exista, contenga todas las columnas requeridas, no presente claves vacías ni duplicadas y mantenga coherencia matemática en sus métricas (por ejemplo, que ningún valor máximo diario sea inferior al promedio del mismo día).



- Tratamiento del archivo Excel estático en corridas horarias

Dado que la API entrega lecturas nuevas cada hora mientras que el archivo Excel funciona como un directorio fijo de infraestructura, fue necesario asegurar la trazabilidad de este último en el tiempo. En cada corrida horaria, el sistema guarda una copia intacta tanto del Excel como de la respuesta cruda de la API dentro de una carpeta identificada por la ejecución, registrando la fecha de lectura, la cantidad de filas y una huella digital criptográfica (SHA-256) del archivo Excel. De esta manera se puede comprobar con exactitud si el catálogo de estaciones se mantuvo idéntico entre horas o si sufrió alguna actualización, conservando las últimas 48 horas de respaldos crudos para no agotar el espacio en disco.

- Estrategia de idempotencia ante re-ejecuciones

Un requisito esencial de cualquier flujo automatizado es que volver a ejecutarlo sobre un mismo periodo no duplique información ni distorsione los indicadores. Para lograrlo, tanto en la capa Silver como en la capa Gold y en la base de datos PostgreSQL se implementó un esquema de actualización por clave única (combinando el identificador de la estación con la fecha u hora de lectura). Cuando una corrida vuelve a procesar datos ya existentes, los registros correspondientes se actualizan en su lugar en vez de añadirse como filas repetidas, y los puestos del ranking diario se recalculan de forma exacta sobre el conjunto consolidado. Las pruebas realizadas confirmaron que tras re-ejecutar el proceso completo se conservan exactamente los mismos 2.289 registros estación-día, cero duplicados y los mismos resultados en todos los indicadores.

4. Indicadores ambientales de desempeño (KPIs)

A partir de la información consolidada en la capa Gold (763 estaciones evaluadas a lo largo de tres jornadas, equivalentes a 2.289 registros estación-día), se definieron cinco indicadores ambientales para evaluar tanto el estado de la contaminación atmosférica como la cobertura y representatividad de la red de monitoreo:

Indicador 1: Índice Nacional de Calidad del Aire de India (NAQI - CPCB)

- Definición: Mide la severidad diaria de la contaminación en una escala oficial de 0 a 500 definida por la autoridad ambiental de India, tomando el subíndice más alto entre los seis contaminantes regulados.

- Fórmula: Máximo subíndice por tramos lineales calculado a partir de las concentraciones diarias de cada contaminante según la tabla oficial CPCB.

- Variables utilizadas: Promedios diarios de PM2.5, PM10, dióxido de nitrógeno, dióxido de azufre, monóxido de carbono y ozono.

- Resultado obtenido: Promedio nacional de 125,76 puntos (categoría Moderada), con valores entre 29,2 y el tope crítico de 500,0 puntos.

Indicador 2: Índice Europeo de Calidad del Aire Promedio Diario (EAQI)

- Definición: Representa el nivel medio diario de deterioro del aire estimado bajo el estándar europeo del modelo Copernicus CAMS.

- Fórmula: Suma de los valores horarios del índice europeo en el día dividida entre el número de horas registradas.

- Variables utilizadas: Índice europeo horario, fecha y código de estación.

- Resultado obtenido: Promedio nacional de 69,62 puntos, alcanzando picos diarios de hasta 507,0 puntos en zonas críticas.

Indicador 3: Porcentaje de excedencia del umbral diario de la OMS para PM2.5

- Definición: Proporción de registros estación-día cuya concentración media de partículas finas PM2.5 supera el límite recomendado por la Organización Mundial de la Salud (15 microgramos por metro cúbico).

- Fórmula: (Cantidad de registros con promedio diario de PM2.5 mayor a 15 / Total de registros estación-día) multiplicado por 100.

- Variables utilizadas: Promedio diario de PM2.5.

- Resultado obtenido: El 88,69 % de las estaciones-día superan el umbral recomendado por la OMS, con una media nacional de 48,49 microgramos por metro cúbico (más del triple del valor guía).

Indicador 4: Cobertura integral de sensores por estación (Red Completa)

- Definición: Porcentaje de estaciones físicas del país que cuentan con equipamiento instalado para vigilar cinco o más contaminantes del aire diferentes.

- Fórmula: (Estaciones con 5 o más contaminantes distintos / Total de estaciones de calidad del aire) multiplicado por 100.

- Variables utilizadas: Identificador de estación, parámetro estandarizado y total de contaminantes monitoreados.

- Resultado obtenido: El 89,91 % de la red (686 de las 763 estaciones) cuenta con cobertura completa.

Indicador 5: Representatividad espacial entre estación y modelo (Distancia Haversine)

- Definición: Distancia geográfica en kilómetros entre la ubicación exacta de la estación en tierra y el centro de la celda del modelo atmosférico que le aporta los datos horarios.

- Fórmula: Distancia geodésica sobre la superficie terrestre a partir de la latitud y

longitud de la estación y las coordenadas del nodo del modelo.

- Variables utilizadas: Latitud y longitud reales de la estación, y latitud y longitud del nodo del modelo.

- Resultado obtenido: Distancia media de 4,19 km y máxima de 7,56 km (el 100 % de las estaciones se encuentra a menos de 15 km de su punto de estimación).

5. Principales hallazgos y limitaciones del proyecto

El análisis conjunto de ambas fuentes permitió identificar comportamientos relevantes tanto desde el punto de vista ambiental como técnico. En primer lugar, la depuración inicial mostró que de los 12.068 registros crudos del archivo Excel, cerca de cuatro mil correspondían a sensores meteorológicos o entradas repetidas, quedando una red efectiva de 7.233 sensores distribuidos en 763 estaciones de calidad del aire (una única estación del catálogo original medía exclusivamente variables climáticas y fue descartada de manera controlada). El cruce geográfico logró cubrir el 100 % de estas 763 estaciones.

En segundo lugar, se evidenció una fuerte concentración de material particulado fino en gran parte del territorio indio: casi nueve de cada diez mediciones diarias superan la guía de la OMS para PM2.5, destacándose episodios severos en el norte y oeste del país (como Hisar y el área metropolitana de Mumbai). La incorporación del índice oficial indio junto al europeo resultó fundamental, ya que la escala europea está pensada para concentraciones bajas y se satura con rapidez ante los niveles habituales de las ciudades indias, mientras que la escala local permite clasificar mejor los rangos altos y distinguir qué contaminante específico domina la alerta de cada día.

En tercer lugar, el estudio puso de relieve la diferencia entre trabajar con un modelo atmosférico regional y con mediciones directas a pie de calle. Debido a que Open-Meteo divide el territorio en cuadrículas de aproximadamente 11 por 11 kilómetros (0,1 grados), las 763 estaciones físicas se agrupan en 460 celdas de consulta únicas. En grandes metrópolis como Nueva Delhi o Mumbai existen numerosas estaciones separadas por pocos kilómetros que caen dentro de una misma cuadrícula (427 estaciones comparten celda con al menos otra estación cercana, llegando hasta 23 estaciones en un mismo sector de Nueva Delhi). Como consecuencia, reciben exactamente la misma estimación horaria y empatan en los rankings individuales, situación que quedó debidamente documentada y resuelta incorporando un ranking adicional por celda geográfica única. Asimismo, se detectó que 133 estaciones del catálogo no registran mediciones físicas recientes en el último año, aunque el modelo numérico continúa estimando la calidad del aire sobre sus coordenadas.

Finalmente, entre las principales limitaciones del pipeline se encuentran la resolución espacial propia del modelo numérico, que suaviza picos muy puntuales causados por el tráfico de una avenida o una chimenea industrial cercana; la naturaleza estática del catálogo en

Excel, cuyos cambios de infraestructura solo se reflejan cuando se reemplaza el archivo; y las restricciones de velocidad de consulta del servicio gratuito de Open-Meteo, las cuales fueron mitigadas agrupando las peticiones por lotes y aplicando pausas controladas entre consultas.